



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
STUDIJŲ PROGRAMA: INFORMATIKA

Anomalijų aptikimas daiktų interneto įrenginių duomenyse **Anomaly Detection in Internet of Things Device Data**

Baigiamasis bakalauro darbas

Atliko: Dovilė Vaiginytė

VU el. p.: dovile.vaiginyte@mif.stud.vu.lt

Darbo vadovas: dr. Igor Katin

Vilnius
2026

Turinys

Išvadas	4
1. Anomalijų aptikimo daiktų interneto duomenyse teoriniai pagrindai	5
1.1. Daiktų interneto duomenų ypatybės	5
1.2. Anomalijų samprata ir tipai	6
1.3. Anomalijų aptikimo metodų apžvalga	7
1.4. Tyrimui pasirinkti metodai	9
1.4.1. K-artimiausių kaimynų (KNN) metodas	9
1.4.2. Vietinio nukrypimo faktoriaus (LOF) metodas	10
1.4.3. Izoliavimo miško (iForest) metodas	11
1.4.4. Pasirinktų metodų palyginimas ir pasirinkimo pagrindimas	12
2. Tyrimo metodika ir sprendimo projektavimas	13
2.1. Tyrimo scenarijus	13
2.2. Sprendimo architektūra ir duomenų kaupimo eiga	13
2.3. Kaupiami duomenys ir jų struktūra.....	15
2.4. Modeliuojamos anomalijos	16
2.5. Duomenų paruošimas analizei.....	17
2.6. Metodų vertinimo kriterijai	19
3. Anomalijų aptikimo metodų taikymas ir rezultatai	21
3.1. Metodų taikymo eiga	21
3.2. KNN metodo taikymo rezultatai	22
3.3. LOF metodo taikymo rezultatai	24
3.4. iForest metodo taikymo rezultatai	26
3.5. Metodų rezultatų palyginimas	27
Išvados	31
Literatūra	33

Santrauka

Daiktų interneto sistemose jutiklių duomenys dažnai naudojami sistemos būsenai stebėti ir sprendimams priimti, todėl jų patikimumas yra svarbus aspektas. Netikslūs, netipiški ar tarpusavyje nesuderinami jutiklių duomenys gali rodyti įrenginio gedimą, ryšio sutrikimą ar kitą nenormalią sistemos būseną. Dėl šios priežasties anomalijų aptikimas daiktų interneto įrenginių duomenyse tampa svarbia analizės dalimi, leidžiančia laiku pastebėti nukrypimus nuo įprasto sistemos veikimo. Šiame darbe buvo išanalizuotos daiktų interneto duomenų ypatybės, anomalijų tipai ir anomalijų aptikimo metodų veikimo principai. Tyrimui apibrėžtas simuliuojamos išmaniosios laistymo sistemos scenarijus, kuriame sistemos būseną apibūdina temperatūros, oro drėgmės, dirvožemio drėgmės, vandens srauto ir laistymo būsenos duomenys. Pagal šį scenarijų įgyvendintas duomenų generavimo bei kaupimo sprendimas, leidžiantis kaupti normalų sistemos veikimą apibūdinančius jutiklių duomenis ir sudaryti anomalijomis papildytą vertinimo duomenų rinkinį. Sugeneruotame duomenų rinkinyje modeliuojami skirtingo pobūdžio nukrypimai, susiję su temperatūros šuoliais, vandens srauto ir laistymo būsenos neatitikimais bei dirvožemio drėgmės kitimu laike. Tyrimui taikyti trys anomalijų aptikimo metodai: K-artimiausių kaimynų, vietinio nukrypimo faktoriaus ir izoliavimo miško. Metodai buvo taikomi naudojant pradinis jutiklių požymius ir papildomus išvestinius dirvožemio drėgmės požymius, apibūdinančius reikšmių kaitą laike. Metodų rezultatai vertinti pagal tikslumą, atkūrimą ir F1 įvertį, taip pat analizuojant, kaip kiekvienas metodas aptinka skirtingų tipų anomalijas.

Rezultatai parodė, kad išvestiniai dirvožemio drėgmės požymiai pagerino visų trijų metodų rezultatus. Geriausią bendrą rezultatą pasiekė vietinio nukrypimo faktoriaus metodas, kurio F1 įvertis siekė 0,640. Šis metodas aptiko 143 iš 150 įterptų anomalijų ir geriausiai atpažino kolektyvinio pobūdžio užstrigusio dirvožemio drėgmės jutiklio anomalijas. K-artimiausių kaimynų metodas taip pat buvo tinkamas daugeliui anomalijų aptikti, tačiau jo bendras rezultatas buvo silpnesnis. Izoliavimo miško metodas šiame tyrimo scenarijuje pasirodė silpniausiai. Gauti rezultatai parodė, kad anomalijų aptikimo kokybė priklauso nuo pasirinkto metodo, naudojamų požymių rinkinio bei anomalijų pobūdžio.

Raktiniai žodžiai: daiktų internetas, anomalijų aptikimas, jutiklių duomenys, laiko eilutės, išmanioji laistymo sistema, K-artimiausi kaimynai, vietinio nukrypimo tankis, izoliavimo miškas.

Abstract

In Internet of Things systems, sensor data is often used to monitor system state and support decision-making, which makes data reliability an important aspect. Inaccurate, atypical, or inconsistent sensor data may indicate device failure, connection failure, or another abnormal system behaviour. For this reason, anomaly detection in Internet of Things device data becomes an important part of data analysis, enabling timely identification of deviations from normal system behavior. This thesis analyzed the characteristics of Internet of Things data, types of anomalies, and the operating principles of anomaly detection methods. A scenario for a simulated smart irrigation system was defined for the study, where the system state is described by temperature, air humidity, soil moisture, water flow, and watering state data. Based on this scenario, a data generation and collection solution was implemented, enabling the collection of sensor data representing normal system behavior and the creation of an evaluation dataset injected with anomalies. The generated dataset simulates various types of deviations related to temperature spikes, inconsistencies between water flow and watering state, and changes in soil moisture over time. Three anomaly detection methods were applied in the study: K-nearest neighbors, local outlier factor, and isolation forest. The methods were applied using the initial sensor features and additional derived soil moisture features describing changes in values over time. The results of the methods were evaluated based on precision, recall, and the F1-score, as well as by analyzing how each method detects different types of anomalies.

The results showed that derived soil moisture features improved the performance of all three methods. The best overall result was achieved by the local outlier factor method, with an F1-score of 0.640. This method detected 143 out of 150 injected anomalies and performed best in identifying collective anomalies related to a stuck soil moisture sensor. The K-nearest neighbors method was also suitable for detecting many anomalies, but its overall result was weaker. The isolation forest method performed the weakest in this study scenario. The obtained results showed that the quality of anomaly detection depends on the chosen method, the feature set used, and the nature of the anomalies.

Keywords: Internet of Things, anomaly detection, sensor data, smart irrigation system, K-nearest neighbors, local outlier factor, isolation forest.

Išvadas

Šiuolaikinėse sistemose vis daugiau sprendimų priklauso ne tik nuo surenkamos informacijos kiekio, bet ir nuo jos patikimumo. Jeigu jutikliai perduoda netikslius, nepilnus ar netipiškus duomenis, tokia informacija gali iškreipti bendrą sistemos būsenos vertinimą ir lemti neteisingas išvadas arba netinkamus valdymo veiksmus. Dėl šios priežasties vis aktualesnis tampa ne vien duomenų kaupimas – ne ką mažiau svarbu gebėti laiku atpažinti neįprastus nukrypimus. Duomenų nukrypimai gali parodyti jutiklio gedimą, ryšio sutrikimą, neteisingą matavimą ar kitą nenormalią sistemos būseną [TKW20]. Anomalijų aptikimas šiuo požiūriu tampa svarbia išmaniųjų sistemų analizės dalimi, nes leidžia anksčiau pastebėti problemas ir padeda didinti bendrą sistemos patikimumą.

Daiktų interneto sistemose ši problema yra ypač svarbi, nes tokios sistemos paprastai veikia nuolat, generuoja laiko eilutėmis išreikštus jutiklių duomenis ir dažnai remiasi kelių tarpusavyje susijusių jutiklių rodmenų analize [HSL⁺23]. Praktikoje tai reiškia, kad nepakanka stebėti tik vieną reikšmę atskirai – svarbu vertinti ir ryšius tarp kelių matuojamų parametrų. Pavyzdžiui, vienos reikšmės pokytis gali būti normalus, tačiau kelių požymių kombinacija jau gali rodyti anomaliją. Todėl anomalijų aptikimas daiktų interneto duomenyse tampa sudėtingesnis nei paprastas ribinių reikšmių tikrinimas ir reikalauja metodų, galinčių analizuoti daugiamatę duomenų aplinką.

Šio darbo tikslas: pritaikyti ir ištirti anomalijų aptikimo metodus daiktų interneto įrenginių duomenims bei įvertinti jų tinkamumą praktiniame daiktų interneto sistemos scenarijuje.

Šiam tikslui pasiekti išsikelti šie uždaviniai:

1. Išanalizuoti daiktų interneto duomenų ypatybes, anomalijų tipus ir aptarti anomalijų aptikimo metodų veikimo principus.
2. Apibrėžti tyrimo scenarijų ir kaupiamų daiktų interneto įrenginių duomenų struktūrą.
3. Sukaupiti tyrimui reikalingus duomenis ir į juos įterpti anomalijas.
4. Paruošti duomenų rinkinį anomalijų aptikimo metodų taikymui.
5. Pritaikyti pasirinktus anomalijų aptikimo metodus naudojant PyOD biblioteką ir palyginti jų rezultatus pagal pasirinktus vertinimo kriterijus.
6. Pateikti tyrimo rezultatus bei išvadas.

1. Anomalijų aptikimo daiktų interneto duomenyse teoriniai pagrindai

Šiame skyriuje aptariami teoriniai pagrindai, reikalingi anomalijų aptikimo daiktų interneto įrenginių duomenyse tyrimui. Pirmiausia apžvelgiamos daiktų interneto duomenų ypatybės, lemiančios jų analizės sudėtingumą. Toliau nagrinėjama anomalijų samprata, jų tipai ir anomalijų aptikimo metodų grupės. Galiausiai pristatomi tyrimui pasirinkti metodai ir pagrindžiamas jų taikymas praktinėje darbo dalyje.

1.1. Daiktų interneto duomenų ypatybės

Daiktų interneto sistemose kaupiami duomenys paprastai apibūdina stebimos aplinkos, įrenginių ar sistemos būseną ir jos kaitą laike [HSL⁺23]. Jutikliai nuolat arba periodiškai registruoja aplinkos, įrenginių ar kitų stebimų objektų parametrus, o surinkti matavimai perduodami tolesniam apdorojimui, kaupimui ir analizei. Tai reiškia, kad daiktų interneto duomenys paprastai nėra pavieniai, vieną kartą sukaupiti įrašai, bet nuolat pildoma stebėjimų seka. Todėl vertinant tokius duomenis svarbu atsižvelgti į jų pokyčius laike, ne vien į atskiras užfiksuotas reikšmes [KKG⁺20].

Viena svarbiausių tokių duomenų savybių yra laiko eilučių pobūdis. Laiko eilutė gali būti suprantama kaip laiko momentais indeksuota stebėjimų seka, kurią bendruoju atveju galima užrašyti poromis $(t_1, x_1), (t_2, x_2), \dots, (t_n, x_n)$, kur t_i žymi laiko momentą, o x_i – tuo metu užfiksuotą reikšmę [HSL⁺23]. Daiktų interneto sistemose tai ypač būdinga, nes jutikliai duomenis generuoja nuosekliai arba suveikus išoriniam įvykiui [KKG⁺20]. Todėl tokie duomenys natūraliai sudaro laiko eilutes arba nuolat atsinaujinančius duomenų srautus. Analizuojant juos svarbu vertinti ne tik atskiras reikšmes, bet ir jų vietą sekoje, pokyčius ankstesnių matavimų atžvilgiu, galimas tendencijas ar periodiškumą [HSL⁺23].

Nemažiau svarbios savybės yra duomenų apimtis ir generavimo sparta. Literatūroje pabrėžiama, kad daiktų interneto jutiklių duomenims būdinga didelė apimtis, spartus generavimas, nuolatinė kaita ir atnaujinimas realiuoju laiku [KKG⁺20]. Praktikoje tai reiškia, kad duomenys gali būti gaunami iš daugelio jutiklių tuo pačiu metu, o skirtingi jutikliai gali perduoti matavimus nevienodu dažniu. Dėl to sistema turi apdoroti ne tik didelę sukaupytų matavimų apimtį, bet ir nuolat gaunamus naujus duomenis. Papildomą sudėtingumą sukuria tarpusavio priklausomybės tarp skirtingų duomenų šaltinių. Tai reiškia, kad kai kurių jutiklių duomenys turi būti vertinami kartu su kitų jutiklių duomenimis tame pačiame laiko kontekste. [KKG⁺20].

Daiktų interneto duomenys taip pat yra heterogeniški (angl. *heterogeneous*). Tai reiškia, kad duomenys yra gaunami iš skirtingų šaltinių ir gali būti pateikiami nevienoda forma. Vieni jutikliai fiksuoja skaitinius dydžius, pavyzdžiui, temperatūrą ar drėgmę. Kiti jutikliai perduoda dvejetaines arba logines būsenas, pavyzdžiui, ar įrenginys yra įjungtas, ar išjungtas. Skirtis gali ir matavimo dažnis, duomenų struktūra bei jų prasmė analizuojamame kontekste. Todėl prieš taikant analizės metodus tokius duomenis dažnai reikia apdoroti, sujungti ir tinkamai paruošti analizei [KKG⁺20].


Dar viena svarbi daiktų interneto duomenų ypatybė yra nevienoda jų kokybė. Literatūroje pažymima, kad neapdorotuose (angl. *raw*) jutiklių duomenyse gali pasitaikyti triukšmo, trūkstamų reikšmių, nukrypimų (angl. *outliers*) ar perteklinių įrašų, todėl prieš analizuojant duomenis, dažnai juos reikia papildomai apdoroti [KKG⁺20]. Tokios problemos gali atsirasti dėl nestabilių belaidžio ryšio kanalų, jutiklių baterijų išsekimo, aplinkos poveikio ar kitų techninių trikdžių. Kadangi prastos kokybės duomenys gali lemti netikslius rezultatus ir klaidingus sprendimus, jų paruošimas tampa svarbia daiktų interneto duomenų analizės dalimi [TKW20].

Apibendrinant galima teigti, kad daiktų interneto duomenys dažnai kaupiami laiko eilučių forma, pasižymi didele apimtimi, įvairove ir nevienoda kokybe. Dėl šių savybių tampa sudėtingiau apibrėžti, kokia sistemos būsena laikytina įprasta, o kokie matavimai rodo reikšmingus nukrypimus nuo normalaus veikimo. Todėl daiktų interneto duomenų analizėje svarbiu uždaviniu tampa tokių nukrypimų nustatymas ir vertinimas.

1.2. Anomalijų samprata ir tipai

Anomalijos paprastai suprantamos kaip duomenyse pasireiškiantys dėsningumai ar reikšmės, neatitinkančios tikėtino normalaus elgesio [CBK09]. Anomalijų aptikimas apima tokių neįprastų ar netikėtų dėsningumų nustatymą duomenyse. Tokie nukrypimai gali būti siejami su gedimais, nepageidaujamu sistemos veikimu, atakomis ar kitomis nenumatytomis situacijomis, kurios išryškėja jutiklių surenkamuose duomenyse [FMS⁺24]. Daiktų interneto sistemose ši samprata yra ypač svarbi, nes jutiklių duomenys naudojami sistemos būsenai stebėti, todėl būtina gebėti atskirti įprastą veikimą nuo neįprastų arba sutrikimus rodančių būsenų [BBR⁺23].

Priklausomai nuo to, kaip nukrypimai pasireiškia duomenyse, anomalijos įprastai skirstomos į tris pagrindinius tipus: taškines, kontekstines ir kolektyvines anomalijas [FMS⁺24]. Šių tipų anomalijų pavyzdžiai atitinkamai pateikti 1 paveikslu a, b ir c dalyse.



1 pav. Skirtingų anomalijų tipų pavyzdžiai: a) Taškinė anomalija, b) Kontekstinė anomalija, c) Kolektyvinė anomalija

Taškinė anomalija (angl. *point anomaly*): pasireiškia tada, kai viena reikšmė aiškiai išsiskiria iš kitų to paties požymio reikšmių. Tokiu atveju neįprastumas pastebimas pavienio taško lygmeniu, nes konkreti reikšmė nukrypsta nuo bendro duomenų pasiskirstymo. Pavyzdžiui, jei temperatūros jutiklis ilgą laiką fiksuoja 22-24 °C intervalą, o vienu momentu užregistruoja 80 °C, toks matavimas galėtų būti laikomas taškine anomalija. Kontekstinė anomalija (angl. *contextual anomaly*):

priklauso nuo aplinkybių, kuriomis vertinama konkreti reikšmė. Tai reiškia, kad ta pati reikšmė vienu atveju gali būti visiškai normali, tačiau kitu atveju tapti neįprasta, jei ji neatitinka savo laiko, vietos ar kito svarbaus konteksto. Pavyzdžiui, jeigu laistymo sistemoje yra fiksuojama vandens srauto reikšmė, ji nėra anomali, jei tuo metu vyksta laistymas. Tačiau, jei ta reikšmė fiksuojama, kai laistymas išjungtas, tai jau gali rodyti sistemos veikimo nukrypimą. Kolektyvinė anomalija (angl. *collective anomaly*): apibūdina situaciją, kai pavienės reikšmės atskirai gali neatrodyti neįprastos, tačiau jų grupė arba seka kaip visuma rodo neįprastą elgesį. Tokiu atveju svarbu ne vien atskiras duomenų taškas, bet bendras kelių reikšmių sekos pobūdis. Pavyzdžiui, viena 45 % dirvožemio drėgmės reikšmė savaime nėra įtartina, tačiau jei jutiklis tam tikrą laiką perduoda visiškai neįprastą reikšmę, tokia seka jau gali rodyti sutrikimą [FMS⁺24].

Daiktų interneto duomenyse šie anomalijų tipai dažnai pasireiškia sudėtingiau nei nagrinėjant vieną atskirą laiko eilutę. Taip yra todėl, kad tokiose sistemose paprastai generuojami daugiamačių laiko eilučių pobūdžio duomenys, kai tuo pačiu arba artimu laiko momentu fiksuojamos kelių požymių reikšmės, pavyzdžiui temperatūra, drėgmė ir laistymo būseną. Tokiuose duomenyse svarbu vertinti ne tik pavienius matavimus, bet ir jų kaitą laike bei ryšius tarp kelių jutiklių. Dėl to anomalija gali išryškėti ne tik kaip vieno požymio reikšmės nukrypimas, bet ir kaip neįprastas kelių požymių derinys, neatitinkantis įprastos sistemos būsenos [BBR⁺23].

Praktikoje daiktų interneto jutiklių duomenyse anomalijos gali pasireikšti skirtingais pavidais. Jos gali būti matomos kaip staigūs pavieniai šuoliai (angl. *spikes*), laipsniškas reikšmių poslinkis laike (angl. *drift*), pastovi, nekintanti reikšmė (angl. *constant value*), užstrigimas ties nuline reikšme (angl. *stuck-at-zero*) ar trūkstamos reikšmės (angl. *missing data*). Tai rodo, kad jutiklių duomenų nukrypimai gali pasireikšti ir kaip pavienės išskirtinės reikšmės, ir kaip tam tikrą laiką trunkantis neįprastas reikšmių kitimas ar nekitimas [TKW20].

Aptarti anomalijų tipai rodo, kad anomalijų aptikimas daiktų interneto sistemų duomenyse negali būti siejamas tik su ribinių reikšmių tikrinimu. Dalis nukrypimų pasireiškia kaip pavienės išskirtinės reikšmės, o kiti išryškėja tik vertinant reikšmių kaitą laike ar kelių jutiklių duomenų tarpusavio suderinamumą. Todėl skirtingo pobūdžio anomalijoms aptikti gali būti reikalingi skirtingais principais veikiantys anomalijų aptikimo metodai.

1.3. Anomalijų aptikimo metodų apžvalga

Anomalijų aptikimo metodus galima apibūdinti keliais aspektais. Vienas iš jų yra mokymosi pobūdis, t. y. tai, kokia informacija apie analizuojamus duomenis yra prieinama metodo taikymo metu. Vienais atvejais metodai gali būti taikomi turint iš anksto pažymėtus normalių ir anomalijų duomenų pavyzdžius, kitais atvejais naudojami tik normalaus veikimo duomenys arba visai nepažymėti duomenys. Kitas aspektas yra anomalumo nustatymo principas – tai, pagal kokias duomenų savybes metodas atskiria įprastus ir anomalius įrašus [FMS⁺24; SWP22].

Pagal mokymosi pobūdį anomalijų aptikimo metodai gali būti skirstomi į prižiūrimus (angl. *supervised*), dalinai prižiūrimus (angl. *semi-supervised*) ir neprižiūrimus (angl. *unsupervised*)

metodus. Prižiūrimi metodai remiasi iš anksto pažymėtais duomenimis, kuriuose mokymo pavyzdžiai priskirti normalių arba anomalijų duomenų klasėms. Tokie metodai gali būti veiksmingi tada, kai turima pakankamai patikimai pažymėtų ir skirtingas situacijas atspindinčių pavyzdžių. Tačiau praktikoje tokias sąlygas užtikrinti sudėtinga, nes anomalijų pavyzdžių paprastai būna mažiau negu normalių, o jų žymėjimas reikalauja daug darbo [CBK09; FMS⁺24]. Dalinai prižiūrimuose metoduose mokymui dažniausiai naudojami tik normalų sistemos veikimą apibūdinantys duomenys. Tokiu atveju sudaromas normalaus elgesio modelis, o anomalijomis laikomi tie duomenų taškai, kurie nuo jo reikšmingai nukrypsta. Neprižiūrimi metodai taikomi tada, kai duomenys neturi iš anksto pateiktų klasių žymių. Tokiu atveju anomalijos nustatomos ne pagal iš anksto pateiktus pavyzdžius, o pagal tai, kiek konkretūs įrašai išsiskiria iš likusio duomenų rinkinio [FMS⁺24; SWP22].

Daiktų interneto duomenų analizėje ypač aktualūs metodai, kuriems nereikia iš anksto pažymėtų anomalijų pavyzdžių. Tokiose sistemose jutikliai generuoja didelius duomenų kiekius, dažnai daugiamačių laiko eilučių forma, o realiose taikymo situacijose šie duomenys paprastai nėra iš anksto pažymėti kaip normalūs ar anomalūs. Dėl to didelių daiktų interneto duomenų kiekių žymėjimas anomalijų aptikimo uždaviniams dažnai tampa nepraktiškas arba neįmanomas [BBR⁺23]. Dėl šios priežasties tokiuose uždaviniuose tikslinga taikyti metodus, kurie gali aptikti nukrypimus neturint iš anksto parengtų anomalijų pavyzdžių.

Be mokymosi pobūdžio, anomalijų aptikimo metodus galima aptarti ir pagal tai, koku principu nustatomas duomenų taško neįprastumas. Vienoje anomalijų aptikimo išmaniosiose aplinkose apžvalgoje tradiciniai metodai grupuojami į statistinius, artumu (angl. *proximity*) ir nuokrypiu (angl. *deviation*) pagrįstus metodus [FMS⁺24]. Statistiniai metodai remiasi prielaida, kad duomenys atitinka tam tikrą tikimybinį pasiskirstymą, todėl anomalijomis laikomi duomenų taškai, kurie nukrypsta nuo tikėtino pasiskirstymo. Artumu pagrįsti metodai anomalijas nustato pagal duomenų taškų padėtį požymių erdvėje. Šiai grupei gali būti priskiriami atstumu pagrįsti metodai, pavyzdžiui, K-artimiausių kaimynų metodas (angl. *K-Nearest Neighbors*, toliau – KNN), kuriame anomalūs laikomi nuo artimiausių kaimynų nutolę duomenų taškai. Šiai grupei taip pat priskiriami tankiu pagrįsti metodai, pavyzdžiui, vietinio nukrypimo faktoriaus (angl. *Local Outlier Factor*, toliau – LOF) metodas, kuriame vertinamas duomenų taško vietinės aplinkos tankis. Be artumu pagrįstų metodų, taikomi ir klasterizavimo metodai, kuriuose anomalijomis gali būti laikomi aiškioms duomenų grupėms nepriklausantys arba nuo jų centrų nutolę taškai [FMS⁺24]. Taip pat viename laiko eilučių anomalijų aptikimo tyrime aptariami ir medžiais arba izoliavimo principu pagrįsti metodai [SWP22]. Tokie metodai, pavyzdžiui, izoliavimo miškas (angl. *Isolation Forest*, toliau – iForest), remiasi idėja, kad išskirtinius duomenų taškus paprastai galima lengviau atskirti nuo likusių duomenų.

Praktiniame anomalijų aptikime svarbu ne tik tai, kaip nustatomas duomenų taško neįprastumas, bet ir kokia forma pateikiamas metodo rezultatas. Anomalijų aptikimo metodų išvestys dažniausiai gali būti dviejų tipų: anomalijos įverčiai arba žymės. Pirmuoju atveju kiekvienam duomenų taškui priskiriama skaitinė reikšmė, rodanti, kiek jis laikomas anomalium. Tokia išvestis leidžia duomenų taškus rikiuoti pagal anomalumo lygį ir, jei reikia, pasirinkti slenkstį, nuo kurio

įrašai laikomi anomalijomis. Antruoju atveju metodas kiekvienam taškui tiesiogiai priskiria žymę – normalus ar anomalus. Taigi įverčiai suteikia daugiau lankstumo interpretuojant rezultatus, o žymės pateikia jau galutinį metodo sprendimą [CBK09].

Kadangi anomalijų aptikimo metodai remiasi skirtingomis prielaidomis, vienas metodas nebūtinai vienodai gerai veikia su skirtingais duomenų rinkiniais. Schimild ir kt. atliktame laiko eilučių anomalijų aptikimo metodų vertinime buvo pakartotinai įgyvendintas ir tarpusavyje palygintas 71 anomalijų aptikimo algoritmas, taikant juos 976 laiko eilučių duomenų rinkiniams. Tyrime pabrėžiama, kad tinkamo algoritmo pasirinkimas konkrečiam anomalijų aptikimo uždaviniui gali būti sudėtingas, nes metodų veiksmingumas priklauso nuo duomenų rinkinio savybių ir anomalijų pobūdžio [SWP22]. Todėl šiame darbe toliau pasirenkami ir palyginami keli skirtingais anomalumo vertinimo principais pagrįsti metodai.

1.4. Tyrimui pasirinkti metodai

Remiantis literatūroje aptariamomis anomalijų aptikimo metodų grupėmis ir siekiant palyginti skirtingais principais veikiančius metodus, tyrimui pasirinkti trys anomalijų aptikimo metodai: KNN, LOF ir iForest. Šie metodai remiasi skirtingais anomalijų nustatymo principais: atstumu iki artimiausių kaimynų, vietinės aplinkos tankiu ir duomenų taškų izoliavimu. Toks pasirinkimas leidžia palyginti, kaip tame pačiame duomenų rinkinyje anomalijas aptinka skirtingais principais veikiantys metodai.


1.4.1. K-artimiausių kaimynų (KNN) metodas

KNN metodas anomalijų aptikimo uždavinyje priskiriamas artimiausių kaimynų analizei pagrįstiems metodams. Šių metodų pagrindinė prielaida yra ta, kad normalūs duomenų taškai paprastai telkiasi tankesnėse duomenų srityse, o anomalūs taškai yra labiau nutolę nuo savo artimiausių kaimynų [CBK09]. Todėl KNN metodas anomalumą vertina pagal tai, kaip konkretus duomenų taškas išsidėsto kitų duomenų taškų atžvilgiu.

Taikant šį metodą, kiekvienas duomenų taškas lyginamas su kitais duomenų rinkinio taškais pagal pasirinktą atstumo matą. Kuo analizuojamas taškas panašesnis į kitus taškus, tuo arčiau jo yra artimiausi kaimynai. Jei taškas yra nutolęs nuo savo artimiausių kaimynų, jis laikomas labiau išsiskiriančiu. Paprasčiausiu KNN anomalijų aptikimo atveju anomalijos įvertis apibrėžiamas kaip atstumas iki k -tojo artimiausio kaimyno: kuo šis atstumas didesnis, tuo didesnis anomalumo įvertis [CBK09]. Šio principo pavyzdys, kai $k = 3$, pateiktas 2 paveiksle, kur matyti, kad vertinamas taškas yra nutolęs nuo tankesnės normalių reikšmių grupės, todėl pagal atstumo iki artimiausių kaimynų principą jam būtų priskiriamas didesnis anomalumo įvertis.

Daugiamatėje duomenų aplinkoje vieną įrašą sudaro keli požymiai. Tokiu atveju KNN metodas leidžia vertinti, ar konkreti kelių požymių kombinacija yra panaši į kitus įrašus, ar reikšmingai nuo jų nutolusi. Kadangi metodas remiasi atstumo arba panašumo tarp duomenų taškų skaičiavimu, daugiamačiams duomenims atstumas paprastai apskaičiuojamas įvertinant atskirus požymius

ir juos sujungiant į bendrą panašumo arba atstumo matą [CBK09].




2 pav. KNN metodo veikimo principas anomalijų aptikime, kai $k = 3$

1.4.2. Vietinio nukrypimo faktoriaus (LOF) metodas

LOF metodas yra tankiu pagrįstas anomalijų aptikimo metodas. Šio metodo esmė yra ta, kad duomenų taškas nebūtinai turi būti stipriai nutolęs nuo viso duomenų rinkinio, kad būtų laikomas neįprastu. Kai kuriais atvejais taškas gali patekti į bendrą duomenų sritį, tačiau vis tiek išsiskirti savo artimiausios aplinkos atžvilgiu. Tai reiškia, kad LOF metodas vertina ne tik bendrą taško padėtį visame duomenų rinkinyje, bet ir tai, kaip jis išsidėsto lyginant su jam artimais taškais. Jeigu analizuojamo taško aplinka yra retesnė negu jo kaimynų aplinka, tokiam taškui priskiriamas didesnis anomalumo įvertis [BKN⁺00].

Taikant LOF metodą, pirmiausia kiekvienam duomenų taškui nustatoma jo kaimynų aibė pagal pasirinktą kaimynų skaičių. Šiame darbe artimiausių kaimynų skaičiaus parametras žymimas k . Remiantis šia kaimynyste įvertinamas analizuojamo taško vietinis tankis, t. y. kiek arti nuo jo yra panašūs duomenų taškai. Vėliau šis tankis lyginamas su artimiausių kaimynų vietiniu tankiu. Jeigu analizuojamo taško aplinka yra retesnė negu jo kaimynų aplinka, jam priskiriamas didesnis anomalumo įvertis, rodantis didesnę išskirtinumą [BKN⁺00]. Šio principo pavyzdys, kai $k = 3$, pateiktas 3 paveiksle. Jame vertinamas taškas (raudonas trikampis) yra netoli kelių artimiausių kaimynų (oranžiniai kvadratai), tačiau jo aplinka yra retesnė negu šių kaimynų aplinka. Todėl pagal LOF metodo logiką tokiam taškui būtų priskiriamas didesnis anomalumo įvertis.




3 pav. LOF metodo veikimo principas, kai $k = 3$

1.4.3. Izoliavimo miško (iForest) metodas

iForest yra medžiais pagrįstas anomalijų aptikimo metodas. Literatūroje šis metodas apibūdinamas kaip atsitiktinių miškų (angl. *Random Forest*) šeimai artimas metodas, skirtas anomalijoms aptikti. Pagrindinė šio metodo idėja yra duomenų taškų izoliavimas, t. y. atskyrimas nuo likusių duomenų [MB21]. Todėl iForest anomalumą vertina pagal tai, kaip greitai konkretų duomenų tašką galima atskirti nuo likusių duomenų.

iForest sudaro daug izoliavimo medžių. Kiekviename tokia medyje duomenys rekursyviai skaidomi į mažesnes dalis: atsitiktinai pasirenkamas požymis ir atsitiktinė skaidymo riba, pagal kurią duomenų taškai padalijami į dvi šakas. Šis procesas kartojamas tol, kol analizuojamas taškas izoliuojamas arba pasiekama nustatyta medžio gylio riba [MB21]. Metodo formuojamų izoliavimo medžių pavyzdys pateiktas 4 paveiksle. Jame mėlynais taškais pažymėti normalūs duomenų taškai, o raudonais – anomalūs duomenų taškai. Paveiksle matyti, kad anomalūs taškai izoliuojami mažesniame medžio gylyje, nes jiems atskirti nuo likusių duomenų reikia mažiau skaidymų.



4 pav. Izoliavimo miško metodo formuojamų medžių pavyzdys

Metodo esmė yra ta, kad anomalūs taškai dažniausiai yra retesni ir labiau išsiskiriantys, todėl jiems izoliuoti paprastai reikia mažiau skaidymų nei normaliems taškams. Dėl šios priežasties anomalijos įvertis siejamas su taško keliu izoliavimo medžiuose: kuo trumpesnis vidutinis kelias iki jo izoliavimo, tuo labiau tas taškas laikomas anomalium [MB21].

1.4.4. Pasirinktų metodų palyginimas ir pasirinkimo pagrindimas

Siekiant aiškiau parodyti tyrimui pasirinktų metodų skirtumus, 1 lentelėje jie palyginami pagal pagrindinį anomalumo nustatymo principą ir anomalijos interpretaciją.

Metodas	Pagrindinis principas	Anomalijos interpretacija
KNN	Atstumas iki artimiausių kaimynų	Anomalus duomenų taškas yra labiau nutolęs nuo kitų panašių taškų
LOF	Vietinės aplinkos tankis	Anomalus duomenų taškas yra retesnėje vietinėje aplinkoje negu jo kaimynai
iForest	Izoliavimas medžiuose	Anomalus duomenų taškas greičiau atskiriamas nuo likusių duomenų

1 lentelė. Tyrimui pasirinktų anomalijų aptikimo metodų palyginimas

Kaip matyti iš lentelės (žr. 1 lentelę), pasirinkti metodai anomalumą vertina nevienodai. KNN ir LOF metodai abu naudoja kaimynystės informaciją, tačiau ją interpretuoja skirtingai: KNN vertina duomenų taško nutolimą nuo artimiausių kaimynų, o LOF – jo vietinės aplinkos tankį kaimynų atžvilgiu. iForest metodas anomalumą nustato pagal tai, kaip greitai duomenų tašką galima izoliuoti nuo likusių duomenų.

Kadangi anomalijų aptikimo metodų pasirinkimas priklauso nuo duomenų savybių ir anomalijų pobūdžio, tinkamiausio metodo pasirinkimas yra gana sudėtingas ir laiko reikalaujantis uždavinys. Todėl šiame darbe pasirinkta tarpusavyje palyginti skirtingais principais veikiančius anomalijų aptikimo metodus, kurių taikymui nėra reikalingos iš anksto pateiktos anomalijų žymės.

2. Tyrimo metodika ir sprendimo projektavimas

Šiame skyriuje aprašoma praktinės darbo dalies tyrimo metodika. Pirmiausia pristatomas pasirinktas išmaniosios laistymo sistemos scenarijus, kuriuo remiantis generuojami daiktų interneto įrenginių duomenys. Toliau aprašoma sprendimo architektūra bei duomenų kaupimo eiga, bendro duomenų rinkinio struktūra, modeliuojamos anomalijos, duomenų paruošimas anomalijų aptikimo metodams ir pasirinktų metodų vertinimo kriterijai.

2.1. Tyrimo scenarijus

Praktinėje darbo dalyje nagrinėjamas simuliuojamas išmaniosios laistymo sistemos scenarijus. Šis scenarijus pasirinktas todėl, kad jame galima modeliuoti daiktų interneto sistemoms būdingą situaciją, kai keli įrenginiai periodiškai generuoja skirtingo pobūdžio duomenis, o bendra sistemos būseną priklauso nuo kelių tarpusavyje susijusių parametrų.

Simuliuojamą sistemą sudaro keli daiktų interneto įrenginiai: temperatūros jutiklis, oro drėgmės jutiklis, dirvožemio drėgmės jutiklis, vandens srauto jutiklis ir laistymo įrenginys. Temperatūros ir oro drėgmės jutikliai skirti aplinkos sąlygoms stebėti ir padeda apibūdinti bendrą sistemos veikimo kontekstą. Dirvožemio drėgmės jutiklis fiksuoja pagrindinį laistymo procesui svarbų parametą – dirvožemio drėgmės lygį. Vandens srauto jutiklis rodo, ar sistemoje teka vanduo, o laistymo įrenginys apibūdina, ar konkrečiu metu laistymas yra įjungtas.

Įprasto veikimo metu laistymo būseną priklauso nuo dirvožemio drėgmės reikšmės. Kai dirvožemio drėgmė sumažėja žemiau nustatytos ribos, laistymas įjungiamas. Laistymo metu sistemoje turi būti fiksuojamas vandens srautas, o dirvožemio drėgmė turėtų palaipsniui didėti. Kai dirvožemio drėgmė pasiekia nustatytą viršutinę ribą arba praeina nustatytas laistymo laikas, laistymas sustabdomas. Nelaistant vandens srautas turėtų būti lygus nuliui, o dirvožemio drėgmė palaipsniui mažėti. Taigi sistemos būseną apibūdinama ne vien atskiromis įrenginių reikšmėmis, bet ir jų tarpusavio ryšiais.


Tyrimo naudojama ne fizinė laistymo sistema, o programinė jos simuliacija. Toks sprendimas leidžia kontroliuoti duomenų generavimo procesą, suformuoti įprastą sistemos veikimą atspindintį duomenų rinkinį ir vėliau modeliuoti nuo jo nukrypstančias situacijas. Taip sudaromos palankios sąlygos anomalijų aptikimo metodų tyrimui ir jų rezultatų palyginimui.

2.2. Sprendimo architektūra ir duomenų kaupimo eiga

Tyrimo duomenims gauti sukurtas simuliacijos sprendimas, sudarytas iš kelių tarpusavyje susijusių komponentų: įrenginių simulatorių, daiktų interneto platformos ThingsBoard [Thi26], lokalių kableliai atskirtų reikšmių (angl. *Comma-Separated Values*, toliau – CSV) failų, duomenų paruošimo modulio ir anomalijų įterpimo modulio. Įrenginių simulatoriai įgyvendinti kaip atskiri Python programos failai. Kiekvienas simulatorius periodiškai generuoja konkretaus komponento reikšmes: temperatūrą, oro drėgmę, dirvožemio drėgmę, vandens srautą bei laistymo būseną.

ThingsBoard platforma šiame sprendime naudojama įrenginių generuojamai telemetrijai priimti, stebėti bei būsenoms sinchronizuoti. Simuliatoriai duomenis į platformą perduoda naudodant žinučių eilės sudarymo telemetrijos transporto (angl. *Message Queuing Telemetry Transport*, MQTT) protokolą. Perduodamos reikšmės gali būti peržiūrimos ThingsBoard skydeliuose (angl. *dashboards*), todėl galima vizualiai stebėti simuliuojamos sistemos būseną ir jautiklių reikšmių kaitą. Be to, platformoje naudojami atributai bei taisyklių grandinės (angl. *Rule Chains*), leidžiantys sinchronizuoti tam tikras įrenginių būsenas. Pavyzdžiui, laistymo būseną perduodama vandens srauto jutikliui, kad vandens srautas būtų generuojamas atsižvelgiant, ar konkrečiu metu laistymas yra įjungtas. Dirvožemio drėgmės jutikliui perduodamos reikalingos aplinkos sąlygos (temperatūra bei oro drėgmė) reikšmės, laistymo būseną ir vandens srauto reikšmė, nes pagal šiuos duomenis apskaičiuojamas tolesnis dirvožemio drėgmės kitimas.

Kartu su duomenų siuntimu į ThingsBoard platformą kiekvieno įrenginio sugeneruoti įrašai išsaugomi ir lokaliuose CSV failuose. Šie failai naudojami tolesniam tyrimo duomenų paruošimui: duomenų paruošimo modulis nuskaito atskirų įrenginių duomenų failus, sujungia jų reikšmes pagal laiką ir sudaro bendrą tyrimo duomenų rinkinį. Vėliau į atskirą vertinimui skirtą duomenų rinkinį anomalijų įterpimo modulis įterpia modeliujamus nukrypimus. Bendra simuliacijos sprendimo ir duomenų sudarymo eiga pateikta 5 paveiksle.



5 pav. Sistemos ir duomenų sudarymo architektūros schema

Kaip matyti iš 5 paveikslo, sprendime išskiriami du pagrindiniai duomenų keliai. Pirmuoju atveju duomenys perduodami į ThingsBoard platformą, kurioje naudojami stebėjimui ir būsenų sinchronizavimui. Antruoju atveju tie patys duomenys kaupiami CSV failuose ir vėliau naudojami

tolesniam apdorojimui bei papildomi modeliujamomis anomalijomis.

2.3. Kaupiami duomenys ir jų struktūra

Iš atskirų įrenginių sukaupytų CSV failų sudaromas bendras tyrimo duomenų rinkinys. Kadangi temperatūros, oro drėgmės, dirvožemio drėgmės, vandens srauto ir laistymo būsenos reikšmės generuojamos atskirai, jų laiko žymos ne visada tiksliai sutampa. Dėl šios priežasties duomenys sujungiami pagal artimiausią laiko momentą. Pagrindine laiko ašimi pasirinkti dirvožemio drėgmės jutiklio įrašai, nes dirvožemio drėgmė šiame scenarijuje yra pagrindinis laistymo proceso stebėjimo parametras. Prie kiekvieno šio jutiklio įrašo prijungiamos artimiausiu metu užfiksuotos temperatūros, oro drėgmės, vandens srauto ir laistymo būsenos reikšmės.

Tyrimo naudojami du atskiri duomenų rinkiniai. Pirmasis rinkinys skirtas anomalijų aptikimo metodų mokymui ir apibūdina normalų simuliuojamos išmaniosios laistymo sistemos veikimą. Jį sudaro 3572 įrašai. Antrasis rinkinys skirtas metodų vertinimui. Iš pradžių jis taip pat sudarytas iš normalaus sistemos veikimą apibūdinančių duomenų, tačiau vėliau į jį įterpiamos modeliujamos anomalijos. Šį rinkinį sudaro 3565 įrašai. Abiejuose rinkiniuose viena eilutė apibūdina sistemos būseną konkrečiu pagrindinės laiko ašies momentu, prie kurio prijungtos kitų įrenginių reikšmės. Duomenų rinkinių struktūra yra vienoda: juos sudaro du pagalbiniai laiko laukai ir penki sistemos būseną apibūdinantys laukai (žr. 2 lentelę).

Laukas	Aprašymas
timestamp_ms	Laiko žyma milisekundėmis, naudojama įrašams rikiuoti ir skirtingų įrenginių reikšmėms sujungti pagal laiką
timestamp	Laiko žyma datos ir laiko formatu, naudojama duomenims peržiūrėti ir rezultatams interpretuoti
temperature	Temperatūros jutiklio užfiksuota aplinkos temperatūros reikšmė
air_humidity	Oro drėgmės jutiklio užfiksuota aplinkos drėgmės reikšmė
soil_moisture	Dirvožemio drėgmės jutiklio užfiksuota dirvožemio drėgmės reikšmė
water_flow	Vandens srauto jutiklio reikšmė, parodanti simuliuojamą vandens tekėjimą sistemoje
watering	Laistymo būseną: 0 – laistymas išjungtas, 1 – laistymas įjungtas

2 lentelė. Pagrindiniai duomenų rinkinių laukai

Laiko laukai timestamp_ms ir timestamp naudojami duomenų sekai sudaryti ir rezultatams analizuoti laiko atžvilgiu. Tuo tarpu sistemos būseną apibūdinantys laukai (temperature, air_humidity, soil_moisture, water_flow ir watering) sudaro pradinį analizuojamų požy-

mių rinkinį. Tolesniame duomenų paruošimo etape šis rinkinys papildomas išvestiniais požymiais, skirtais dirvožemio drėgmės kaitai apibūdinti.

2.4. Modeliuojamos anomalijos

Tyrimo naudojamas duomenų rinkinys su modeliuojamomis anomalijomis sudaromas remiantis normalaus išmaniosios laistymo sistemos veikimo duomenimis. Į vertinimui skirtą duomenų rinkinį įterpiami iš anksto apibrėžti nukrypimai, atspindintys neįprastą jutiklių reikšmių arba sistemos būsenos elgseną. Toks sprendimas leidžia kontroliuoti anomalijų pobūdį ir turėti žinomas tikrąsias anomalijų žymes, kurios vėliau naudojamos metodų rezultatams įvertinti.

Modeliuojamos anomalijos pasirinktos taip, kad apimtų skirtingus išmaniosios laistymo sistemos veikimo nukrypimus: neįprastą pavienio jutiklio reikšmę, laistymo būsenos ir vandens srauto neatitikimą, dirvožemio drėgmės jutiklio užstrigimą bei situaciją, kai laistymo metu dirvožemio drėgmė nedidėja. Šie nukrypimai siejami su teorinėje dalyje (žr. 1.2. poskyrį) aptartais anomalijų tipais. Dalis jų pasireiškia kaip pavienės reikšmės šuolis, dalis – kaip kelių požymių tarpusavio neatitikimas, o dalis išryškėja tik vertinant reikšmių kaitą laike. Toks anomalijų rinkinys leidžia patikrinti, kaip pasirinkti metodai aptinka ne tik aiškiai išsiskiriančias reikšmes, bet ir sudėtingesnius nukrypimus, susijusius su sistemos būsenos kontekstu. Modeliuojamų anomalijų tipai, jų pobūdis ir įrašų skaičius pateikti 3 lentelėje.

Anomalijos tipas	Aprašymas	Pobūdis	Įrašų sk.
Temperatūros šuolis	Staigus temperatūros reikšmės šuolis, neatitinkantis įprastos aplinkos temperatūros kaitos	Taškinė anomalija	5
Vandens srautas nelaistant	Vandens srautas fiksuojamas tuo metu, kai laistymas yra išjungtas	Kontekstinė anomalija	35
Laistymas be vandens srauto	Laistymas yra įjungtas, tačiau vandens srauto jutiklis nefiksuoja vandens tekėjimo	Kontekstinė anomalija	25
Užstrigęs dirvožemio drėgmės jutiklis	Dirvožemio drėgmės reikšmė tam tikrą laiką išlieka nekintanti arba beveik nekintanti	Kolektyvinė anomalija	60
Laistymas be dirvožemio drėgmės reakcijos	Laistymo metu fiksuojamas vandens srautas, tačiau dirvožemio drėgmė nedidėja taip, kaip tikėtina įprasto veikimo metu	Kontekstinė / kolektyvinė anomalija	25

3 lentelė. Tyrime modeliuojami anomalijų tipai

Modeliuojamų anomalijų įrašų skaičius pasirinktas atsižvelgiant į anomalijos pobūdį ir siekį sudaryti vertinimui tinkamą duomenų rinkinį. Taškinio pobūdžio temperatūros šuolio anomalija įterpiama 5 įrašuose, nes tokio tipo nukrypimas pasireiškia trumpai ir aiškiai išsiskiria konkrečiu matavimo momentu. Kontekstinės anomalijos, susijusios su vandens srauto ir laistymo būsenos

neatitikimais, įterpiamos ilgesnėmis atkarpomis: vandens srauto nelaistant anomalijai skirti 35 įrašai, o laistymo be vandens srauto anomalijai – 25 įrašai. Taip siekiama įvertinti, ar metodai aptinka pasikartojančią netipinę sistemos būseną. Užstrigusio dirvožemio drėgmės jutiklio anomalijai pasirinkta 60 įrašų, nes tokio tipo anomalija išryškėja, kai reikšmė nekinta ilgesnį laiką. Laistymo be dirvožemio drėgmės reakcijos anomalijai skirti 25 įrašai, nes šis nukrypimas taip pat turi būti vertinamas per tam tikrą laiko intervalą. Iš viso į vertinimo duomenų rinkinį įterpta 150 anomalijų, todėl jos sudaro tik nedidelę dalį viso rinkinio, o normalūs įrašai išlieka dominuojantys (3415 įrašai).

Temperatūros šuolio anomalija modeliuoja situaciją, kai temperatūros jutiklis perduoda trumpalaikę, nuo įprastos temperatūros kaitos aiškiai nutolusią reikšmę. Ši anomalija laikoma taškine, nes jos neįprastumas gali būti pastebimas vertinant pavienę temperatūros reikšmę. Vandens srauto ir laistymo būsenos neatitikimai modeliuoja situacijas, kai sistemos būsena tampa logiškai nesuderinama su vandens srauto jutiklio reikšme. Įprasto veikimo metu, kai laistymas išjungtas, vandens srautas neturėtų būti fiksuojamas. Todėl atvejis, kai vandens srautas fiksuojamas nelaistant, laikomas kontekstine anomalija. Priešinga situacija, kai laistymas įjungtas, tačiau vandens srautas nefiksuojamas, taip pat laikoma kontekstine anomalija.

Dirvožemio drėgmės jutiklio užstrigimo anomalija skiriasi nuo pavienio reikšmės šuolio, nes pati dirvožemio drėgmės reikšmė nebūtinai yra neįprasta. Ji gali patekti į normalaus veikimo intervalą, tačiau ilgesnį laiką nekintanti reikšmių seka gali rodyti sutrikimą. Dėl šios priežasties ši anomalija priskiriama kolektyvinėms anomalijoms. Laistymo be dirvožemio drėgmės reakcijos anomalija priklauso tiek nuo sistemos būsenos, tiek nuo reikšmių kaitos laike. Įprasto veikimo metu, kai laistymas įjungtas ir fiksuojamas vandens srautas, dirvožemio drėgmė turėtų palaipsniui didėti. Jeigu laistymas vyksta, tačiau dirvožemio drėgmė nedidėja arba toliau mažėja, toks elgesys laikomas nukrypimu nuo įprastos sistemos veikimo logikos.

Įterpus anomalijas, duomenų rinkinys papildomas dviem žymėjimo laukais: `is_anomaly` ir `anomaly_type`. Laukas `is_anomaly` nurodo, ar konkretus įrašas yra normalus (reikšmė lygi 0), ar anomalus (reikšmė lygi 1). Laukas `anomaly_type` nurodo konkretų anomalijos tipą, o normaliems įrašams priskiriama reikšmė `normal`. Šie laukai nėra naudojami kaip anomalijų aptikimo metodų įvesties požymiai, tačiau jie reikalingi rezultatams palyginti su žinomomis anomalijų žymėmis.

2.5. Duomenų paruošimas analizei

Sudarius mokymui ir vertinimui skirtus duomenų rinkinius, jie papildomai apdorojami anomalijų aptikimo metodų taikymui. Šiame etape atrenkami metodams naudojami požymiai, sudaromi papildomi išvestiniai požymiai ir suvienodinami požymių masteliai. Duomenų paruošimas reikalingas tam, kad skirtingais principais veikiančioms metodams būtų pateikiama vienoda ir palyginama įvestis.

Kadangi dalis modeliujamų anomalijų yra susijusios su dirvožemio drėgmės reikšmės kitimu laike, vien momentinės dirvožemio drėgmės reikšmės tokioms anomalijoms apibūdinti neužtenka.

Pasirinktiems metodams pateikiami atskiri duomenų įrašai su požymių reikšmėmis, todėl reikšmių kaitą per kelis matavimus reikia išreikšti papildomai. Dėl šios priežasties duomenų rinkinys papildomas trimis išvestiniais požymiais, apskaičiuojamai pagal dirvožemio drėgmės (soil_moisture) reikšmių seką. Jie skirti trumpalaikiam reikšmės pokyčiui bei kintamumui apibūdinti ir suteikia metodams papildomos informacijos apie tai, kaip dirvožemio drėgmė keičiasi per kelis iš eilės einančius matavimus. Išvestiniai požymiai pateikiami 4 lentelėje.

Išvestinis požymis	Aprašymas
soil_moisture_change	Dirvožemio drėgmės pokytis nuo ankstesnio matavimo
soil_moisture_change_10	Dirvožemio drėgmės pokytis per 10 matavimų langą.
soil_moisture_std_10	Dirvožemio drėgmės kintamumas per 10 matavimų langą, apskaičiuojamas naudojant standartinį nuokrypį

4 lentelė. Išvestiniai dirvožemio drėgmės požymiai

Požymis soil_moisture_change parodo, kiek dirvožemio drėgmės reikšmė pasikeitė nuo ankstesnio matavimo. Jeigu reikšmė teigiama, dirvožemio drėgmė padidėjo, o jeigu neigiama – sumažėjo. Taip pateikiama informacija apie dirvožemio drėgmės pokytį tarp dviejų iš eilės einančių matavimų. soil_moisture_change_10 parodo dirvožemio drėgmės pokytį per 10 matavimų. Jis leidžia įvertinti trumpesnio laikotarpio tendenciją, pavyzdžiui, ar laistymo metu dirvožemio drėgmė didėja. Požymis soil_moisture_std_10 parodo, kiek dirvožemio drėgmė svyruoja 10 matavimų lange. Jeigu reikšmės beveik nekinta, šio požymio reikšmė tampa maža, todėl jis gali padėti apibūdinti užstrigusio dirvožemio jutiklio tipo nukrypimus.

Kadangi dviems išvestiniams požymiams apskaičiuoti naudojamas 10 matavimų langas, duomenų rinkinio pradžioje nepakanka ankstesnių reikšmių jiems apskaičiuoti. Todėl metodų taikymo etape pirmosios 10 eilučių nėra naudojamos. Taip išvengiama situacijos, kai pradinės, dar nepakankamai informatyvios slenkančio lango reikšmės paveiktų anomalijų aptikimo metodų rezultatus. Galutinį metodams perduodamų požymių rinkinį sudaro pradiniai sistemos būseną apibūdinantys požymiai: temperature, air_humidity, soil_moisture, water_flow, watering ir išvestiniai dirvožemio drėgmės požymiai: soil_moisture_change, soil_moisture_change_10, soil_moisture_std_10.

Prieš taikant anomalijų aptikimo metodus, požymių masteliai suvienodinami standartizuojant duomenis. Standartizavimo metu iš kiekvienos požymio reikšmės atimamas to požymio vidurkis, o gautas skirtumas padalijamas iš standartinio nuokrypio. Taip požymiai, kurių reikšmės yra skirtinguose intervaluose, tampa palyginami tarpusavyje. Pavyzdžiui, temperatūros ar oro drėgmės reikšmės gali būti matuojamos dešimtimis, o dirvožemio drėgmės pokyčio požymiai gali būti daug mažesni. Jei masteliai nebūtų suvienodinti, didesnes skaitines reikšmes turintys požymiai galėtų

daryti neproporcingai didelę įtaką metodų rezultatams. Tai ypač svarbu KNN ir LOF metodams, nes jie remiasi atstumais arba kaimynystės informacija požymių erdvėje. Standartizavimo parametrai, t. y. kiekvieno požymio vidurkis ir standartinis nuokrypis, apskaičiuojami tik pagal mokymui skirtą normalaus veikimo duomenų rinkinį. Vėliau tie patys parametrai pritaikomi ir vertinimui skirtam duomenų rinkiniui su modeliuojamomis anomalijomis. Tai reiškia, kad vertinimo rinkinys nėra naudojamas standartizavimo parametrams apskaičiuoti. Tokiu būdu išvengiama situacijos, kai informacija iš vertinimo duomenų būtų panaudota duomenų paruošimo etape.

2.6. Metodų vertinimo kriterijai

Kadangi vertinimui skirtame duomenų rinkinyje anomalijos įterpiamos kontroliuojamai, kiekvienam įrašui žinoma tikroji klasė: normalus įrašas ar anomalija. Todėl anomalijų aptikimo metodų rezultatai gali būti vertinami lyginant metodų prognozuotas žymes su tikrosiomis anomalijų žymėmis. Vertinimui pasirinktos tikslumo (angl. *precision*), atkūrimo (angl. *recall*) ir F1 įverčio (angl. *F1-score*) metrikos. Šios metrikos leidžia įvertinti skirtingus anomalijų aptikimo kokybės aspektus ir yra naudojamos anomalijų aptikimo metodų vertinimui [FMS⁺24].

Toliau vertinant metodų rezultatus naudojamos keturios sprendimų grupės:

- TP (angl. *true positive*) – anomalūs įrašai, teisingai pažymėti kaip anomalijos;
- FP (angl. *false positive*) – normalūs įrašai, klaidingai pažymėti kaip anomalijos;
- FN (angl. *false negative*) – anomalūs įrašai, klaidingai palikti normaliais;
- TN (angl. *true negative*) – normalūs įrašai, teisingai palikti normaliais.

Tikslumas parodo, kokia metodo anomalijomis pažymėtų įrašų dalis iš tikrųjų yra anomalijos. Ši metrika apskaičiuojama pagal (1) formulę.

$$\text{Tikslumas} = \frac{TP}{TP + FP} \quad (1)$$

Pagal (1) formulę, tikslumas priklauso nuo teisingai aptiktų anomalijų ir klaidingai anomalijomis pažymėtų normalių įrašų skaičiaus. Maža tikslumo reikšmė rodo, kad metodas daug normalių įrašų klaidingai pažymi kaip anomalijas.

Atkūrimas parodo, kokią visų realių anomalijų dalį metodas aptiko. Atkūrimas apskaičiuojamas pagal (2) formulę.

$$\text{Atkūrimas} = \frac{TP}{TP + FN} \quad (2)$$

Pagal (2) formulę, atkūrimas priklauso nuo teisingai aptiktų anomalijų ir neaptiktų anomalijų skaičiaus. Ši metrika parodo metodo gebėjimą nepraleisti realių anomalijų. Maža atkūrimo reikšmė reiškia, kad dalis anomalijų lieka nepatikta.

F1 įvertis apjungia tikslumą ir atkūrimą į vieną bendrą įvertį. Jis apskaičiuojamas pagal (3) formulę.

$$F1 = 2 \cdot \frac{Tikslumas \cdot Atkūrimas}{Tikslumas + Atkūrimas} \quad (3)$$

F1 įvertis naudojamas bendram metodų palyginimui, nes leidžia įvertinti balansą tarp teisingai aptiktų anomalijų ir klaidingai anomalijomis pažymėtų normalių įrašų. Ši metrika ypač naudinga tada, kai vien tik tikslumo arba vien tik atkūrimo reikšmė nepakankamai gerai parodo metodo veikimą.

Be bendrų metrikų, rezultatai papildomai analizuojami pagal atskirus anomalijų tipus. Toks vertinimas leidžia nustatyti, kokio pobūdžio anomalijas kiekvienas tyrime naudojamas anomalijų aptikimo metodas aptinka geriau arba prasčiau.

3. Anomalijų aptikimo metodų taikymas ir rezultatai

Šiame skyriuje pateikiamas pasirinktų anomalijų aptikimo metodų taikymas ir gauti rezultatai. Pirmiausia aprašoma bendra metodų taikymo eiga, naudojami požymių rinkiniai ir rezultatų vertinimo principas. Toliau atskirai nagrinėjami KNN, LOF ir iForest metodų rezultatai, o skyriaus pabaigoje geriausi metodų rezultatai palyginami tarpusavyje pagal 2.6. poskyryje apibrėžtas metrikas bei anomalijų tipus.

3.1. Metodų taikymo eiga

Tyrimui atlikti ir anomalijų aptikimo metodams taikyti naudojama atvirojo kodo Python biblioteką PyOD. Šioje bibliotekoje yra įgyvendinta daug įvairių anomalijų aptikimo metodų, tarp jų ir šiame darbe pasirinkti KNN, LOF bei iForest metodai [ZNL19]. Todėl PyOD šiame darbe naudojama pasirinktiems metodams apmokyti ir prognozuojamoms anomalijų žymėms gauti.

Siekiant užtikrinti palyginamus rezultatus, visiems metodams naudojami tie patys mokymo ir vertinimo duomenų rinkiniai. Mokymui naudojamas normalaus sistemos veikimo duomenų rinkinys, o vertinimui – atskiras duomenų rinkinys su įterptomis anomalijomis. Tikrosios anomalijų žymės naudojamos tik rezultatams įvertinti, tačiau jos nėra perduodamos metodams, kaip įvesties požymiai. Kadangi vertinimui skirtame duomenų rinkinyje anomalijos įterpiamos kontroliuojamai, visiems metodams nustatyta vienoda numatoma anomalijų dalis. PyOD bibliotekoje šis nustatymas atitinka `contamination` parametą. Jis naudotas tam, kad metodai būtų lyginami taikant vienodą anomalijų proporcijos prielaidą.

Kiekvienas metodas taikomas su dviem požymių rinkinio variantais. Pirmuoju atveju naudojami tik pradiniai sistemos būseną apibūdinantys požymiai: `temperature` – temperatūra, `air_humidity` – oro drėgmė, `soil_moisture` – dirvožemio drėgmė, `water_flow` – vandens srautas ir `watering` – laistymo būseną. Antruoju atveju prie šių požymių papildomai pridedami išvestiniai dirvožemio drėgmės požymiai: `soil_moisture_change`, `soil_moisture_change_10` ir `soil_moisture_std_10`, kurie apibūdina dirvožemio drėgmės kitimą laike (žr. 4 lentelę). Toks palyginimas leidžia įvertinti, ar papildoma informacija apie dirvožemio drėgmės kitimą laike pagerina anomalijų aptikimo rezultatus.

Abiems požymių rinkinio variantams taikoma ta pati duomenų paruošimo eiga: pirmosios 10 eilučių nenaudojamos dėl slenkančio lango požymių skaičiavimo, o požymių masteliai suvienodinami standartizuojant duomenis. Tokiu būdu visiems metodams pateikiama vienodai paruošta įvestis. Gauti rezultatai vertinami pagal 2.6. poskyryje apibrėžtas metrikas – tikslumą, atkūrimą ir $F1$ įvertį. Be to, papildomai analizuojama, kiek kiekvieno tipo anomalijų aptinka atskiri metodai, kad būtų galima įvertinti tinkamumą skirtingo pobūdžio anomalijoms aptikti.

3.2. KNN metodo taikymo rezultatai

Kadangi KNN metodo tikslumui įtakos gali turėti artimiausių kaimynų skaičiaus pasirinkimas, šis metodas taikytas su šešiomis skirtingomis artimiausių kaimynų skaičiaus parametro reikšmėmis. Eksperimentuose naudotos $k = 5, 10, 20, 30, 40, 50$ artimiausių kaimynų reikšmės. Kiekvienas atvejis išbandytas su 3.1. poskyryje aprašytais dviem požymių rinkinio variantais: pradinio požymių rinkiniu ir pradinio rinkiniu, papildytu išvestiniais dirvožemio drėgmės požymiais. Kiti KNN metodo parametrai palikti numatytaisiais PyOD bibliotekos. Tokiu pasirinkimu buvo siekiama įvertinti, kaip rezultatams daro įtaką tiek kaimynų skaičius, tiek papildoma informacija apie dirvožemio drėgmės kaitą laike.

KNN metodo rezultatai pagal tikslumą, atkūrimą ir F1 įvertį, su skirtingais požymių rinkiniais ir skirtingomis artimiausių kaimynų skaičiaus k reikšmėmis pateikti 5 lentelėje. Čia P žymi pradinį požymių rinkinį, o P + I – pradinį požymių rinkinį kartu su išvestiniais dirvožemio drėgmės požymiais. Toks pat žymėjimas naudojamas aptariant ir kitų metodų rezultatus.

Požymių rinkinys	k	Tikslumas	Atkūrimas	F1 įvertis
P	5	0,258	0,467	0,333
P	10	0,283	0,453	0,349
P	20	0,295	0,433	0,351
P	30	0,311	0,433	0,362
P	40	0,325	0,433	0,371
P	50	0,323	0,433	0,370
P + I	5	0,389	0,820	0,528
P + I	10	0,383	0,767	0,511
P + I	20	0,404	0,700	0,512
P + I	30	0,363	0,620	0,458
P + I	40	0,389	0,593	0,470
P + I	50	0,392	0,593	0,472

5 lentelė. KNN metodo rezultatai su skirtingais požymių rinkiniais ir kaimynų skaičiumi

Kaip matyti iš 5 lentelėje pateiktų rezultatų, naudojant tik pradinius požymius, KNN metodo rezultatai buvo silpnesni: geriausias F1 įvertis siekė 0,371, kai kaimynų skaičius buvo 40. Papildžius vertinamų požymių rinkinį išvestiniais, geriausias F1 įvertis padidėjo iki 0,528, kai kaimynų skaičius buvo 5. Šiuo atveju metodas pasiekė 0,389 tikslumą ir 0,820 atkūrimą. Tai rodo, kad išvestiniai dirvožemio drėgmės požymiai pagerino KNN metodo gebėjimą aptikti anomalijas. Vertinant skirtingas k reikšmes matyti, kad didinant kaimynų skaičių, atkūrimo reikšmė mažėjo, todėl tai reiškia, kad buvo aptinkama mažiau realių anomalijų. Nors kai kuriais atvejais didesnė k reikšmė šiek tiek padidino tikslumą, šis pagerėjimas ne kompensavo sumažėjusio atkūrimo. Todėl pagal

bendrą F1 įvertį geriausi KNN rezultatai šiame tyrime gauti su pradiniais ir išvestiniais požymiais, kai $k = 5$.

Geriausio rezultato atveju metodas teisingai aptiko 123 anomalijas iš 150, o 27 anomalijos liko neaptiktos. Taip pat 193 normalūs įrašai iš 3405 vertintų normalių įrašų buvo klaidingai pažymėti kaip anomalijos, o 3212 normalūs įrašai teisingai palikti normaliais. Tai rodo, kad KNN metodas su išvestiniais požymiais aptiko didelę dalį įterptų anomalijų, tačiau klaidingų teigiamų aptikimų skaičius išliko gana reikšmingas: iš visų 316 anomalijomis pažymėtų įrašų tik 123 buvo tikros anomalijos.

Kadangi tyrime modeliuojamos anomalijos skiriasi ne tik įrašų skaičiumi, bet ir pobūdžiu, geriausios KNN konfigūracijos rezultatai papildomai įvertinti pagal anomalijų tipus. 6 lentelėje pateikiama, kiek kiekvieno tipo anomalijų buvo įterpta į vertinimo duomenų rinkinį ir kiek jų aptiko KNN metodas.

Anomalijos tipas	Iš viso	Aptikta
Temperatūros šuolis	5	5
Vandens srautas nelaistant	35	35
Laistymas be vandens srauto	25	25
Užstrigęs dirvožemio drėgmės jutiklis	60	34
Laistymas be dirvožemio drėgmės reakcijos	25	24

6 lentelė. KNN metodo aptiktos anomalijos pagal tipus, kai naudojami P + I požymiai ir $k = 5$

Iš 6 lentelės matyti, kad KNN metodas geriausiai aptiko taškines ir kontekstines anomalijas: aptikti visi 5 temperatūros šuolio, 35 vandens srauto nelaistant ir 25 laistymo be vandens srauto atvejai. Taip pat aptikti 24 iš 25 laistymo be dirvožemio drėgmės reakcijos atvejai. Ši anomalija priklauso nuo sistemos būsenos ir dirvožemio drėgmės pokyčio laike, todėl jos aptikimui buvo svarbūs išvestiniai požymiai.

Sunkiausiai metodui sekėsi aptikti užstrigusio dirvožemio drėgmės jutiklio anomalijas – aptikti 34 iš 60 atvejų. Ši anomalija priskirta kolektyvinėms anomalijoms, nes jos neįprastumas išryškėja ilgesnėje reikšmių sekoje. Naudojant tik pradinius požymius ir keičiant kaimynų parametro reikšmę, šio tipo anomalijos nebuvo aptiktos nė karto. Tai rodo, kad vien momentinės dirvožemio drėgmės reikšmės nepakako šiam anomalijos tipui atpažinti. Išvestiniai požymiai, apibūdinantys šios reikšmės kitimą laike, leido aptikti dalį šių anomalijų, tačiau šis anomalijos tipas KNN metodui išliko sudėtingiausias.

Apibendrinant galima teigti, kad KNN metodo rezultatai tyrime pagerėjo papildžius požymių rinkinį išvestiniais požymiais. Geriausias bendras rezultatas gautas naudojant mažą kaimynų skaičių, kai $k = 5$. Metodas gerai aptiko taškines ir kontekstines anomalijas, tačiau kolektyvinio pobūdžio užstrigusio dirvožemio drėgmės jutiklio anomalijos jam išliko sudėtingesnės.

3.3. LOF metodo taikymo rezultatai

LOF metodo atveju artimiausių kaimynų skaičius svarbus, nes nuo jo priklauso, kokio dydžio vietinė duomenų taško aplinka naudojama tankiui įvertinti. Todėl šio metodo taikymo eksperimentuose taip pat keistas kaimynų skaičiaus parametras. Pagrindiniuose eksperimentuose naudotos tos pačios k reikšmės, kaip ir KNN metodo atveju: $k = 5, 10, 20, 30, 40, 50$. Kiekvienas atvejis išbandytas su 3.1. poskyryje aprašytais dviem tais pačiais požymių rinkiniais: pradinių požymių rinkiniu ir pradiniu rinkiniu, papildytu išvestiniais požymiais. Kiti LOF metodo parametrai palikti numatytaisiais PyOD bibliotekos. LOF metodo rezultatai su skirtingais požymių rinkiniais ir skirtingomis kaimynų skaičiaus k reikšmėmis pateikti 7 lentelėje. Lentelėje nurodomas naudotas požymių rinkinys, k reikšmė, tikslumas, atkūrimas ir F1 įvertis.

Požymių rinkinys	k	Tikslumas	Atkūrimas	F1 įvertis
P	5	0,115	0,733	0,199
P	10	0,125	0,693	0,212
P	20	0,150	0,633	0,242
P	30	0,199	0,560	0,293
P	40	0,233	0,553	0,328
P	50	0,248	0,533	0,338
P + I	5	0,167	0,987	0,286
P + I	10	0,214	0,987	0,352
P + I	20	0,299	0,933	0,452
P + I	30	0,383	0,953	0,547
P + I	40	0,426	0,953	0,588
P + I	50	0,432	0,953	0,595

7 lentelė. LOF metodo rezultatai su skirtingais požymių rinkiniais ir kaimynų skaičiumi

Vertinant 7 lentelėje pateiktus rezultatus matyti, naudojant tik pradinių požymių rinkinį, geriausias F1 įvertis siekė 0,338, kai $k = 50$. Papildžius požymių rinkinį išvestiniais požymiais, F1 įvertis pakilo iki 0,595, kai kaimynų skaičius taip pat buvo 50. Šiuo atveju metodas pasiekė 0,432 tikslumą ir 0,953 atkūrimą. Tai rodo, kad išvestiniai dirvožemio drėgmės požymiai reikšmingai pagerino LOF metodo rezultatus. Be to, naudojant pradinių ir išvestinių požymių rinkinį, pastebėta, kad F1 įvertis didėjo didinant kaimynų skaičiaus parametro reikšmę. Dėl šios priežasties papildomai patikrintos dvi didesnės kaimynų skaičiaus reikšmės: $k = 75$ ir $k = 100$. Papildomo patikrinimo tikslumo, atkūrimo ir F1 įverčio rezultatai, naudojant P + I požymių rinkinį, pateikti 8 lentelėje.

Požymių rinkinys	k	Tikslumas	Atkūrimas	F1 įvertis
P + I	50	0,432	0,953	0,595
P + I	75	0,481	0,953	0,640
P + I	100	0,469	0,860	0,607

8 lentelė. LOF metodo patikrinimas su didesnėmis k reikšmėmis, naudojant P + I požymius

Papildomas patikrinimas parodė, kad geriausias LOF metodo rezultatas gautas naudojant pradinis ir išvestinius požymius, kai $k = 75$. Šiuo atveju F1 įvertis padidėjo iki 0,640. Toliau didinant kaimynų skaičių iki $k = 100$, F1 įvertis sumažėjo iki 0,607, todėl geriausia metodo konfigūracija šiame tyrime laikoma P + I požymių rinkinys, kai $k = 75$.

Geriausio rezultato atveju metodas teisingai aptiko 143 anomalijas iš 150, o 7 anomalijos liko neaptiktos. Taip pat 154 iš 3405 vertintų normalių įrašų buvo klaidingai pažymėti kaip anomalijos, o 3251 normalus įrašas teisingai paliktas normaliu. Nors LOF metodas aptiko didžiąją dalį įterptų anomalijų, tikslumo reikšmė 0,481 rodo, kad tarp anomalijomis pažymėtų įrašų išliko nemažai klaidingų aptikimų. Mažesnių k reikšmių atveju ši problema buvo dar ryškesnė, pavyzdžiui, naudojant P + I požymius ir $k = 5$, anomalijomis klaidingai pažymėti 738 normalūs įrašai.

Geriausios LOF konfigūracijos rezultatai papildomai įvertinti pagal anomalijų tipus. Vertinimo duomenų rinkinyje įterptų skirtingų tipų anomalijų skaičius ir LOF metodo aptiktų skirtingų anomalijų skaičius pateikiamas 9 lentelėje.

Anomalijos tipas	Iš viso	Aptikta
Temperatūros šuolis	5	5
Vandens srautas nelaistant	35	35
Laistymas be vandens srauto	25	25
Užstrigęs dirvožemio drėgmės jutiklis	60	54
Laistymas be dirvožemio drėgmės reakcijos	25	24

9 lentelė. LOF metodo aptiktos anomalijos pagal tipus, kai naudojami P + I požymiai ir $k = 75$

Pagal 9 lentelėje pateiktus rezultatus matyti, kad LOF metodas aptiko visas 5 temperatūros šuolio, 35 vandens srauto nelaistant ir 25 laistymo be vandens srauto anomalijas. Taip pat praleido tik vieną laistymo be dirvožemio drėgmės reakcijos atvejį (aptiko 24 iš 25). Tai rodo, kad metodas gerai aptiko tiek taškinio, tiek kontekstinio pobūdžio anomalijas. Prasčiausiai LOF metodas aptiko užstrigusio dirvožemio drėgmės jutiklio anomalijas, kurios yra kolektyvinio pobūdžio. Šio tipo anomalijų buvo aptikta 54 iš 60 atvejų. Tačiau rezultatas nėra blogas – matyti, kad didžioji dalis anomalijų buvo aptiktos teisingai. Tokiam rezultatui įtakos turėjo požymių rinkinio papildymas išvestiniais požymiais. Naudojant tik pagrindinius požymius, geriausias užstrigusio jutiklio anomalijos aptikimas buvo 34 iš 60 atvejų, kai $k = 5$.

Apibendrinant galima teigti, kad geresnius rezultatus LOF metodui pasiekti padėjo požymių rinkinio papildymas išvestiniais požymiais. Taip pat, pastebėta, kad geresni rezultatai buvo gauti su didesne kaimynų skaičiaus parametro reikšme, todėl geriausias bendras rezultatas gautas naudojant $P + I$ požymių rinkinį ir $k = 75$. LOF metodas gerai aptiko taškinio ir kontekstinio pobūdžio anomalijas, o taip pat aptiko daugumą kolektyvinio pobūdžio užstrigusio dirvožemio drėgmės jutiklio anomalijų, nors jos ir buvo sudėtingiausios.

3.4. iForest metodo taikymo rezultatai

iForest metodo atveju metodas taip pat taikytas su dviem tais pačiais, 3.1. poskyryje apibrėžtais, požymių rinkiniais, kaip ir kiti du metodai. Kadangi iForest algoritme medžių sudarymas priklauso nuo atsitiktinių pasirinkimų, rezultatų atkartojamumui naudota fiksuota atsitiktinumų reikšmė. Kiti iForest metodo parametrai palikti numatytaisiais PyOD bibliotekos. iForest metodo rezultatai su skirtingais požymių rinkiniais pateikti 10 lentelėje, kurioje nurodomas naudotas požymių rinkinys, tikslumas, atkūrimas ir F1 įvertis.

Požymių rinkinys	Tikslumas	Atkūrimas	F1 įvertis
P	0,023	0,020	0,022
P + I	0,180	0,167	0,173

10 lentelė. iForest metodo rezultatai su skirtingais požymių rinkiniais

Pagal metodo rezultatus, pateiktus 10 lentelėje, galima matyti, kad naudojant tik pradinį požymių rinkinį iForest metodo F1 įvertis buvo 0,022, o papildžius požymių rinkinį išvestiniais dirvožemio drėgmės požymiais, F1 įvertis padidėjo iki 0,173. Šiuo atveju metodas pasiekė 0,180 tikslumą ir 0,167 atkūrimą. Tai rodo, kad išvestiniai požymiai pagerino iForest metodo rezultatą, tačiau bendras anomalijų aptikimo lygis išliko žemas.

Geriausio rezultato atveju metodas teisingai aptiko 25 anomalijas iš 150, o 125 anomalijos liko neaptiktos. Normalių įrašų, kurie klaidingai pažymėti kaip anomalijos, skaičius siekė 114 iš 3405 vertintų normalių įrašų, o 3291 normalus įrašas teisingai paliktas normaliu. Tai rodo, kad šiame tyrimo scenarijuje iForest metodas aptiko tik nedidelę dalį įterptų anomalijų.

Siekiant detaliau įvertinti, kokias anomalijas aptiko geriausią rezultatą parodęs iForest variantas, rezultatai suskirstyti pagal anomalijų tipus. 11 lentelėje pateikta, kiek kiekvieno tipo anomalijų buvo įterpta į vertinimo duomenų rinkinį ir kiek jų aptiko iForest metodas.

Anomalijos tipas	Iš viso	Aptikta
Temperatūros šuolis	5	0
Vandens srautas nelaistant	35	0
Laistymas be vandens srauto	25	9
Užstrigęs dirvožemio drėgmės jutiklis	60	0
Laistymas be dirvožemio drėgmės reakcijos	25	16

11 lentelė. iForest metodo aptiktos anomalijos pagal tipus, kai naudojami P + I požymiai

Iš 11 lentelės matyti, kad iForest metodas aptiko tik dalį dviejų anomalijų tipų: 9 iš 25 laistymo be vandens srauto anomalijų ir 16 iš 25 laistymo be dirvožemio drėgmės reakcijos anomalijų. Vandens srauto nelaistant anomalijų buvo įterpta 35, užstrigusio dirvožemio drėgmės jutiklio anomalijų – 60, o temperatūros šuolio anomalijų – 5, tačiau šių tipų anomalijų iForest metodas neaptiko nė vienos. Tai rodo, kad šiame duomenų rinkinyje iForest metodui buvo sudėtinga aptikti tiek kontekstines ir kolektyvines, tiek ir pavienes taškines anomalijas.

Tokį rezultatą galima sieti su tuo, kad iForest anomalumą vertina pagal tai, kaip lengvai duomenų taškas izoliuojamas izoliavimo medžiuose. Nors temperatūros šuolis yra taškinė anomalija, ji šiame tyrime pasireiškė tik viename požymyje. Jeigu kiti to paties įrašo požymiai išliko artimi normaliems sistemos įrašams, tokie taškai galėjo būti nebūtinai pakankamai išsiskiriantys bendroje daugiamatėje požymių erdvėje. Todėl metodas jų nepriskyrė anomalijoms. Panašiai galima aiškinti ir vandens srauto nelaistant anomalijos rezultatą. Šiuo atveju neįprasta yra ne pati vandens srauto reikšmė ar pati laistymo būseną atskirai, bet jų tarpusavio derinys. Kadangi iForest remiasi atsitiktiniu požymių skaidymu, tokio tipo loginis neatitikimas nebūtinai tampa lengvai izoliuojamas. Tai galėjo lemti, kad šio tipo anomalijos nebuvo aptiktos, nors jos yra aiškiai apibrėžtos pagal sistemos veikimo logiką.

Apibendrinant galima teigti, kad iForest metodo rezultatai pagerėjo pridėjus išvestinius dirvožemio drėgmės požymius, tačiau bendras šio metodo veikimas šiame išmaniosios laistymo sistemos tyrimo scenarijuje išliko ribotas. Metodas aptiko tik dalį dviejų modeliujamų anomalijų tipų, o vandens srauto nelaistant, užstrigusio dirvožemio drėgmės jutiklio ir temperatūros šuolio anomalijų neaptiko visai.

3.5. Metodų rezultatų palyginimas

Šiame poskyryje apibendrinami ir tarpusavyje palyginami geriausi kiekvieno tyrime naudoto anomalijų aptikimo metodo rezultatai. Kadangi ankstesniuose poskyriuose kiekvienas metodas buvo vertintas atskirai, čia lyginamos tik geriausios KNN, LOF ir iForest metodų konfigūracijos. Metodai lyginami pagal 2.6. poskyryje apibrėžtas metrikas: tikslumą, atkūrimą ir F1 įvertį. Tikslumas parodo, kiek metodo anomalijomis pažymėtų įrašų iš tikrųjų buvo anomalijos, atkūrimas – kiek visų realių anomalijų metodas aptiko, o F1 įvertis apibendrina tikslumo ir atkūrimo balansą. Geriausių metodų konfigūracijų rezultatai pateikti 12 lentelėje. Joje nurodoma geriausia kiekvieno

metodo konfigūracija ir pagal ją gautos tikslumo, atkūrimo bei F1 įverčio reikšmės.

Metodas	Geriausia konfigūracija	Tikslumas	Atkūrimas	F1 įvertis
KNN	P + I, $k = 5$	0,389	0,820	0,528
LOF	P + I, $k = 75$	0,481	0,953	0,640
iForest	P + I	0,180	0,167	0,173

12 lentelė. Geriausių metodų konfigūracijų rezultatų palyginimas

Iš 12 lentelės matyti, kad geriausią bendrą rezultatą pasiekė LOF metodas. Jo F1 įvertis siekė 0,640, o atkūrimas – 0,953. Tai reiškia, kad šis metodas aptiko didžiausią dalį realių anomalijų. LOF metodas teisingai aptiko 143 iš 150 anomalijų, tačiau 154 iš 3405 normalius įrašus klaidingai pažymėjo kaip anomalijas. Taigi, nors metodas pasiekė geriausią rezultatą, klaidingų teigiamų aptikimų problema išliko. KNN metodas taip pat aptiko didelę dalį anomalijų – 123 iš 150, tačiau jo F1 įvertis buvo mažesnis ir siekė 0,528. Šio metodo atkūrimas buvo 0,820, todėl dalis anomalijų liko neaptikta. Be to, KNN metodas klaidingai anomalijomis pažymėjo 193 normalius įrašus iš 3405. iForest metodas šiame tyrimo scenarijuje pasiekė silpniausią rezultatą: jo F1 įvertis siekė tik 0,173, o aptiktos buvo 25 iš 150 anomalijų.

Visų trijų metodų geriausi rezultatai buvo gauti naudojant pradinį požymių rinkinį su išvestiniais dirvožemio drėgmės požymiais. Tai rodo, kad anomalijų aptikimui šiame scenarijuje buvo svarbios ne tik momentinės jutiklių reikšmės, bet ir dirvožemio drėgmės kitimas laike. Šie požymiai ypač svarbūs anomalijoms, kurių neįprastumas išryškėja per reikšmių seką arba per sistemos būsenos ir reikšmės pokyčio neatitikimą.

Toliau metodų rezultatai palyginami pagal atskirus anomalijų tipus. Šis palyginimas leidžia įvertinti, ar metodai vienodai gerai aptiko skirtingo pobūdžio anomalijas. 13 lentelėje pateikta, kiek kiekvieno tipo anomalijų buvo įterpta į vertinimo duomenų rinkinį ir kiek jų aptiko geriausios KNN, LOF bei iForest metodų konfigūracijos.


Anomalijos tipas	Iš viso	KNN	LOF	iForest
Temperatūros šuolis	5	5	5	0
Vandens srautas nelaistant	35	35	35	0
Laistymas be vandens srauto	25	25	25	9
Užstrigęs dirvožemio drėgmės jutiklis	60	34	54	0
Laistymas be dirvožemio drėgmės reakcijos	25	24	24	16

13 lentelė. Aptiktų anomalijų skaičiaus palyginimas pagal anomalijų tipus

Iš 13 lentelės matyti, kad KNN ir LOF metodai gerai aptiko taškinio ir kontekstinio pobūdžio anomalijas. Abu metodai aptiko visus 5 temperatūros šuolio, 35 vandens srauto nelaistant ir 25 laistymo be vandens srauto atvejus. Taip pat abu metodai aptiko 24 iš 25 laistymo be dirvožemio


drėgmės reakcijos anomalijas. Didžiausias skirtumas tarp KNN ir LOF metodų išryškėjo aptinkant užstrigusio dirvožemio drėgmės jutiklio anomalijas. KNN metodas aptiko 34 iš 60 šio tipo anomalijų, o LOF – 54 iš 60. Kadangi ši anomalija yra kolektyvinio pobūdžio ir išryškėja per ilgesnę reikšmių seką, geresnis LOF rezultatas leidžia daryti prielaidą, kad šiame duomenų rinkinyje vietinės aplinkos tankio vertinimas buvo tinkamesnis šiam anomalijos tipui negu atstumas iki artimiausių kaimynų. iForest metodas pagal anomalijų tipus pasirodė silpniausiai. Jis neaptiko vandens srauto nelaistant, užstrigusio dirvožemio drėgmės jutiklio ir temperatūros šuolio anomalijų. Dalis laistymo be vandens srauto (9 iš 25) ir laistymo be dirvožemio drėgmės reakcijos (16 iš 25) anomalijų buvo aptikta, tačiau bendras aptiktų anomalijų skaičius išliko mažas.

Siekiant vizualiai parodyti modeliujamų anomalijų pobūdį bei metodų aptikimus, toliau pateikiami trys anomalijų pavyzdžiai iš naudoto duomenų rinkinio. Paveiksluose tuščiaviduriai mėlyni apskritimai žymi tikrąsias anomalijas, o raudoni trikampiai, žali kryželiai ir geltoni kvadratai – atitinkamai KNN, LOF ir iForest metodų anomalijomis pažymėtus įrašus.




6 pav. Temperatūros šuolio anomalijos aptikimo pavyzdys

Temperatūros šuolio pavyzdyje (žr. 6 pav.) matyti pavieniai staigūs temperatūros reikšmės pakilimai. Šios anomalijos yra taškinio pobūdžio, nes išsiskiria atskiromis reikšmėmis. Grafike matyti, kad KNN ir LOF metodai pažymėjo temperatūros šuolio anomalijas, o iForest metodas jų neaptiko. Tai atitinka 13 lentelėje pateiktus rezultatus.



7 pav. Užstrigusio dirvožemio drėgmės jutiklio anomalijos aptikimo pavyzdys

Užstrigusio dirvožemio drėgmės jutiklio pavyzdyje (žr. 7 pav.) matyti ilgesnė nekintanti dirvožemio drėgmės reikšmių atkarpa. Ši anomalija nėra aiškiai matoma kaip vienas išskirtinis taškas, todėl jos aptikimui svarbus reikšmių kitimas laike. Grafike matyti, kad LOF metodas pažymėjo didesnę šios anomalijos atkarpos dalį, o KNN aptikimai apėmė mažesnę jos dalį. iForest metodas šios anomalijos neaptiko.



8 pav. Laistymo be dirvožemio drėgmės reakcijos anomalijos aptikimo pavyzdys

Laistymo be dirvožemio drėgmės reakcijos pavyzdyje (žr. 8 pav.) pilkai pažymėtas intervalas, kuriame vyksta laistymas. Čia matyti situacija, kai dirvožemio drėgmė nedidėja taip, kaip būtų tikėtina laistymo metu. Ši anomalija susijusi ne tik su konkrečia reikšme, bet ir su jos pokyčiu laike, todėl ji priskirta kontekstinėms / kolektyvinėms anomalijoms. Grafike matyti, kad visi trys metodai pažymėjo dalį šio intervalo įrašų, tačiau bendruose rezultatuose KNN ir LOF šį anomalijos tipą aptiko tiksliau negu iForest.

Apibendrinant galima teigti, kad geriausią rezultatą šiame išmaniosios laistymo sistemos tyrimo scenarijuje pasiekė LOF metodas su pradinių ir išvestinių požymių rinkiniu. KNN metodas taip pat buvo tinkamas daugeliui modeliuotų anomalijų aptikti, tačiau prasčiau aptiko užstrigusio dirvožemio drėgmės jutiklio anomalijas. iForest metodas šiame duomenų rinkinyje buvo mažiausiai tinkamas, nes aptiko tik nedidelę dalį anomalijų. Bendri rezultatai rodo, kad anomalijų aptikimo kokybė priklausė ne tik nuo pasirinkto metodo, bet ir nuo požymių rinkinio bei konkretaus anomalijos tipo pasireiškimo duomenyse.

Išvados

- Išanalizavus daiktų interneto duomenų ypatybes, anomalijų tipus ir anomalijų aptikimo metodų veikimo principus nustatyta, kad daiktų interneto įrenginių duomenims būdingas laiko eilučių pobūdis, kelių požymių tarpusavio priklausomybės ir nevienoda duomenų kokybė. Dėl šių savybių anomalijų aptikimas negali būti siejamas tik su pavienių ribinių reikšmių tikrinimu, nes anomalijos gali pasireikšti ne tik kaip atskiri reikšmių šuoliai, bet ir kaip požymių tarpusavio neatitikimai arba ilgesnės reikšmių sekos pokyčiai.
- Pasirinktas simuliuojamos išmaniosios laistymo sistemos scenarijus pasirodė tinkamas anomalijų aptikimo daiktų interneto duomenyse tyrimui, nes jame sistemos būseną priklauso nuo kelių tarpusavyje susijusių parametrų. Šis scenarijus leido sudaryti duomenų struktūrą, apimančią temperatūros, oro drėgmės, dirvožemio drėgmės, vandens srauto ir laistymo būsenos duomenis. Tokia struktūra leido vertinti skirtingo pobūdžio nukrypimus, susijusius tiek su pavienėmis jutiklių reikšmėmis, tiek su kelių parametrų tarpusavio neatitikimais.
- Sukauptas ir anomalijomis papildytas vertinimo duomenų rinkinys sudarė pagrindą anomalijų aptikimo metodų palyginimui. Į šį rinkinį įterpta 150 skirtingo pobūdžio anomalijų: temperatūros šuolis, vandens srauto nelaistymas, laistymas be vandens srauto, užstrigęs dirvožemio drėgmės jutiklis ir laistymas be dirvožemio drėgmės reakcijos. Toks anomalijų rinkinys leido įvertinti, kaip pasirinkti metodai aptinka taškinės, kontekstines ir kolektyvines anomalijas.
- Duomenų paruošimo etape nustatyta, kad šiame simuliuojamos išmaniosios laistymo sistemos anomalijų aptikimo tyrime pradiniai sistemos būseną apibūdinantys požymiai nepakankamai gerai apibūdina anomalijas, kurios susijusios su dirvožemio drėgmės kaita laike. Dėl to duomenų rinkinys papildytas išvestiniais dirvožemio drėgmės požymiais. Tyrimo rezultatai parodė, kad šie požymiai pagerino visų trijų metodų rezultatus, todėl galima teigti, kad reikšmių kintamumą apibūdinantys požymiai buvo svarbūs šiame anomalijų aptikimo scenarijuje.
- Pritaikius KNN, LOF ir iForest metodus simuliuojamos išmaniosios laistymo sistemos duomenims nustatyta, kad geriausią bendrą rezultatą pasiekė LOF metodas su pradinių ir išvestinių požymių rinkiniu, kai kaimynų skaičius buvo 75. Šio metodo F1 įvertis siekė 0,640, atkūrimas – 0,953, o tikslumas – 0,481. KNN metodas taip pat aptiko didelę dalį anomalijų, tačiau jo F1 įvertis buvo mažesnis ir siekė 0,528. iForest metodas šiame tyrimo scenarijuje pasirodė silpniausiai – jo F1 įvertis siekė 0,173.
- Apibendrinus tyrimo rezultatus nustatyta, kad metodų veikimas priklauso ne tik nuo pasirinkto algoritmo, bet ir nuo anomalijos pobūdžio. KNN ir LOF metodai gerai aptiko temperatūros šuolio, vandens srauto nelaistymo ir laistymo be vandens srauto anomalijas. Didžiausias skirtumas tarp šių metodų išryškėjo aptinkant užstrigusio dirvožemio drėgmės jutiklio anomalijas. Šiuo atveju KNN aptiko 34 iš 60 šio tipo anomalijų, o LOF – 54 iš 60. Tai rodo,

kad LOF metodas šiame duomenų rinkinyje geriau tiko kolektyvinio pobūdžio anomalijoms aptikti.

Parengtas simuliacijos sprendimas ir atliktas metodų palyginimas gali būti naudojami kaip pagrindas tolimesniam anomalijų aptikimo taikymui realių daiktų interneto sistemų duomenims. Kadangi šiame darbe naudoti kontroliuojamai sugeneruoti duomenys, taikant metodus realioje daiktų interneto sistemoje jų veikimą reikėtų įvertinti su faktiniais jutiklių duomenimis, kuriuose gali būti daugiau triukšmo, trūkstamų reikšmių ar kitokių anomalijų pasireiškimo formų.

Literatūra

- [BBR⁺23] Mohammed Ayalew Belay, Sindre Stenen Blakseth, Adil Rasheed, and Pierluigi Salvo Rossi. Unsupervised anomaly detection for iot-based multivariate time series: existing solutions, performance analysis and future directions. *Sensors*, 23:1–24, 2023. URL: https://www.researchgate.net/publication/369038409_Unsupervised_Anomaly_Detection_for_IoT-Based_Multivariate_Time_Series_Existing_Solutions_Performance_Analysis_and_Future_Directions.
- [BKN⁺00] Markus Breunig, Peer Kröger, Raymond Ng, and Joerg Sander. Lof: identifying density-based local outliers. In *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104, New York, NY, USA. Association for Computing Machinery, 2000. URL: https://www.researchgate.net/publication/221214719_LOF_Identifying_Density-Based_Local_Outliers.
- [CBK09] Varun Chandola, Arindam Banerjee, and Vipin Kumar. Anomaly detection: a survey. *ACM Comput. Surv.*, 41:15:1–15:58, 2009. URL: https://www.researchgate.net/publication/220565847_Anomaly_Detection_A_Survey.
- [FMS⁺24] Daniel Fährmann, Laura Martín, Luis Sánchez, and Naser Damer. Anomaly detection in smart environments: a comprehensive survey. *IEEE Access*, PP:64006–64049, 2024. URL: <https://ieeexplore.ieee.org/abstract/document/10510320>.
- [HSL⁺23] Chaochen Hu, Zihan Sun, Chao Li, Yong Zhang, and Chunxiao Xing. Survey of time series data generation in iot. *Sensors*, 23:1–23, 2023. URL: <https://www.mdpi.com/1424-8220/23/15/6976>.
- [KKG⁺20] Rajalakshmi Krishnamurthi, Adarsh Kumar, Dhanalekshmi Gopinathan, Anand Nayar, and Basit Qureshi. An overview of iot sensor data processing, fusion, and analysis techniques. *Sensors*, 20:1–23, 2020. URL: <https://www.mdpi.com/1424-8220/20/21/6076>.
- [MB21] Antonella Mensi and Manuele Bicego. Enhanced anomaly scores for isolation forests. *Pattern Recognition*, 120:108115, 2021. URL: <https://www.sciencedirect.com/science/article/pii/S0031320321003022>.
- [SWP22] Sebastian Schmidl, Phillip Wenig, and Thorsten Papenbrock. Anomaly detection in time series: a comprehensive evaluation. *Proceedings of the VLDB Endowment*, 15:1779–1797, 2022. URL: <https://publishup.uni-potsdam.de/frontdoor/index/index/docId/66366>.
- [Thi26] ThingsBoard. ThingsBoard Documentation. <https://thingsboard.io/docs/>, 2026. Tikrinta 2026-05-17.

- [TKW20] Hui Yie Teh, Andreas W. Kempa-Liehr, and Kevin I-Kai Wang. Sensor data quality: a systematic review. *Journal of Big Data*, 7:1–49, 2020. URL: <https://link.springer.com/article/10.1186/s40537-020-0285-1>.
- [ZNL19] Yue Zhao, Zain Nasrullah, and Zheng Li. Pyod: a python toolbox for scalable outlier detection. *Journal of Machine Learning Research*, 20:1–7, 2019. URL: https://www.researchgate.net/publication/334099069_PyOD_A_Python_Toolbox_for_Scalable_Outlier_Detection.